A Quantitative Study of Two Matrix Clustering Algorithms

Александр Слесарев
студент СПбГУ, 2-й курс

Вячеслав Галактионов, Никита Бобров, Георгий Чернышев
СПбГУ, JetBrains Research

SEIM 2019
13 апреля 2019

Типы фрагментирования

- Горизонтальное фрагментирование
- Вертикальное фрагментирование
- Гибридное фрагментирование

Число возможных фрагментов

Число Белла – число всех неупорядоченных разбиений n-элементного множества

При больших n выполняется $B(n) \approx n^n$, например, $B(30) \approx 10^{23}$

n	$B(n)$
1	1
2	1
3	2
4	5
5	15
6	52
7	203
8	877
9	4140
10	21147
11	115975

Виды вертикального фрагментирования

- стоимостное
- эвристическое
  - методы матричной кластеризации
  - графовый подход
  - data mining

О проекте

Цель: экспериментальная проверка алгоритмов ВФ на основе подхода матричной кластеризации

Современные работы по ВФ на матричной кластеризации:

- C. Cheng “Algorithms for vertical partitioning in database physical design”, **1993**
- C.-H. Cheng “A branch and bound clustering algorithm”, **1995**
- C.-H. Cheng and J. Motwani “An examination of cluster identification-based algorithms for vertical partitions”, **2009**
- C.-H. Cheng et al. “An improved branch-and-bound clustering approach for data partitioning”, **2011**

Наши предыдущие работы:

- V. Galaktionov et al. “Matrix clustering algorithms for vertical partitioning problem: an initial performance study”, **2016**
- V. Galaktionov “Parallelization of matrix clustering algorithms”, **2016**
- V. Galaktionov et al. “A study of several matrix-clustering vertical partitioning algorithms in a disk-based environment”, **2017**

Матрица запросов

q1: SELECT a FROM T WHERE a $>$ 10;
q2: SELECT b, f FROM T;
q3: SELECT a, c FROM T WHERE a = c;
q4: SELECT a FROM T WHERE a $<$ 10;
q5: SELECT e FROM T;
q6: SELECT d, e FROM T WHERE d + e $>$ 0;

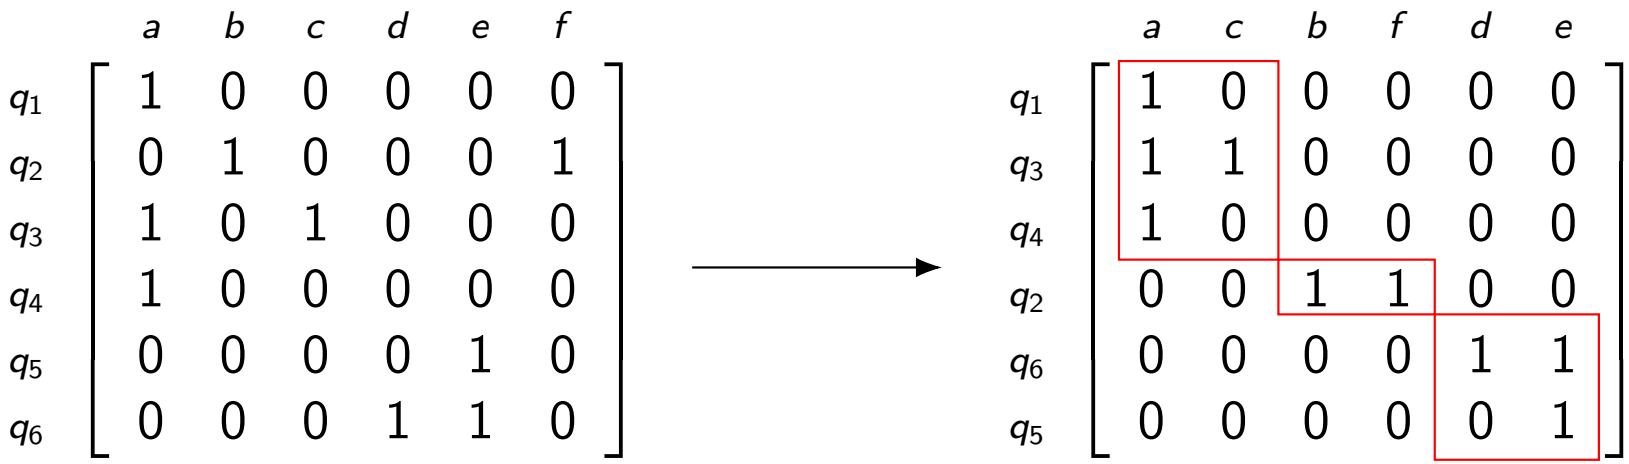

Cluster identification

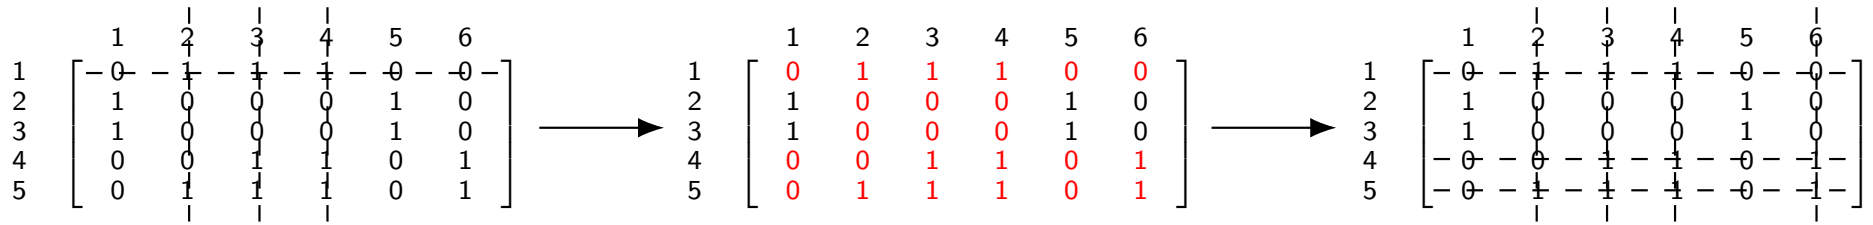

$$\begin{array}{c} \\ 1 \\ 4 \\ 5 \\ 2 \\ 3 \end{array} \begin{array}{c} \begin{array}{cccccc} 2 & 3 & 4 & 6 & 1 & 5 \end{array} \\ \begin{bmatrix} 1 & 1 & 1 & 0 & 0 & 0 \\ 0 & 1 & 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 0 & 1 & 1 \end{bmatrix} \end{array}$$

Поиск решения – 1

M – матрица запросов

M_i^j – i-й узел на j-ом уровне фрагментирования

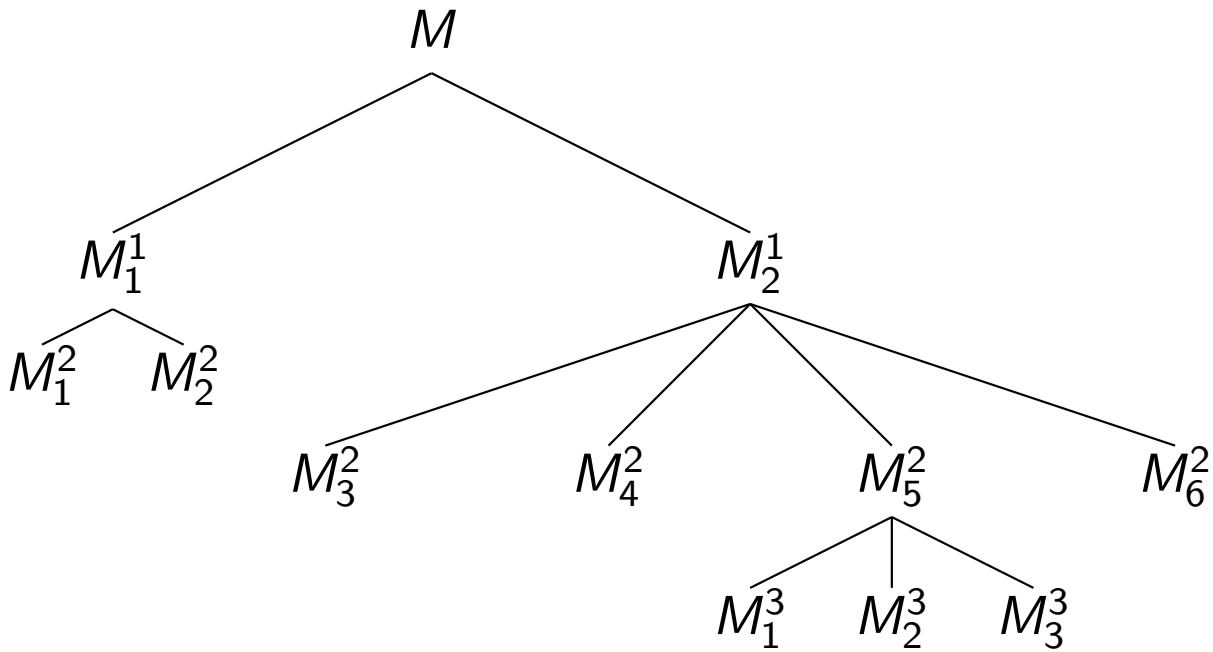

Поиск решения – 2

R - множество индексов транзакций M

C - множество индексов атрибутов M

$$cohesion(M) = \frac{|\{a_{ij} = 1, i \in R \wedge j \in C\}|}{|R| * |C|}$$

Набор кластеров - решение, если каждый кластер S удовлетворяет условиям:

- $cohesion(S) < threshold$
- В S отсутствуют нулевые строки или столбцы

Метод ветвей и границ 2009 – 1

нижняя граница: Z_L – число единиц, удаленных из матрицы транзакции в ходе ветвления

верхняя граница: Z_U – минимальный Z_L среди найденных решений

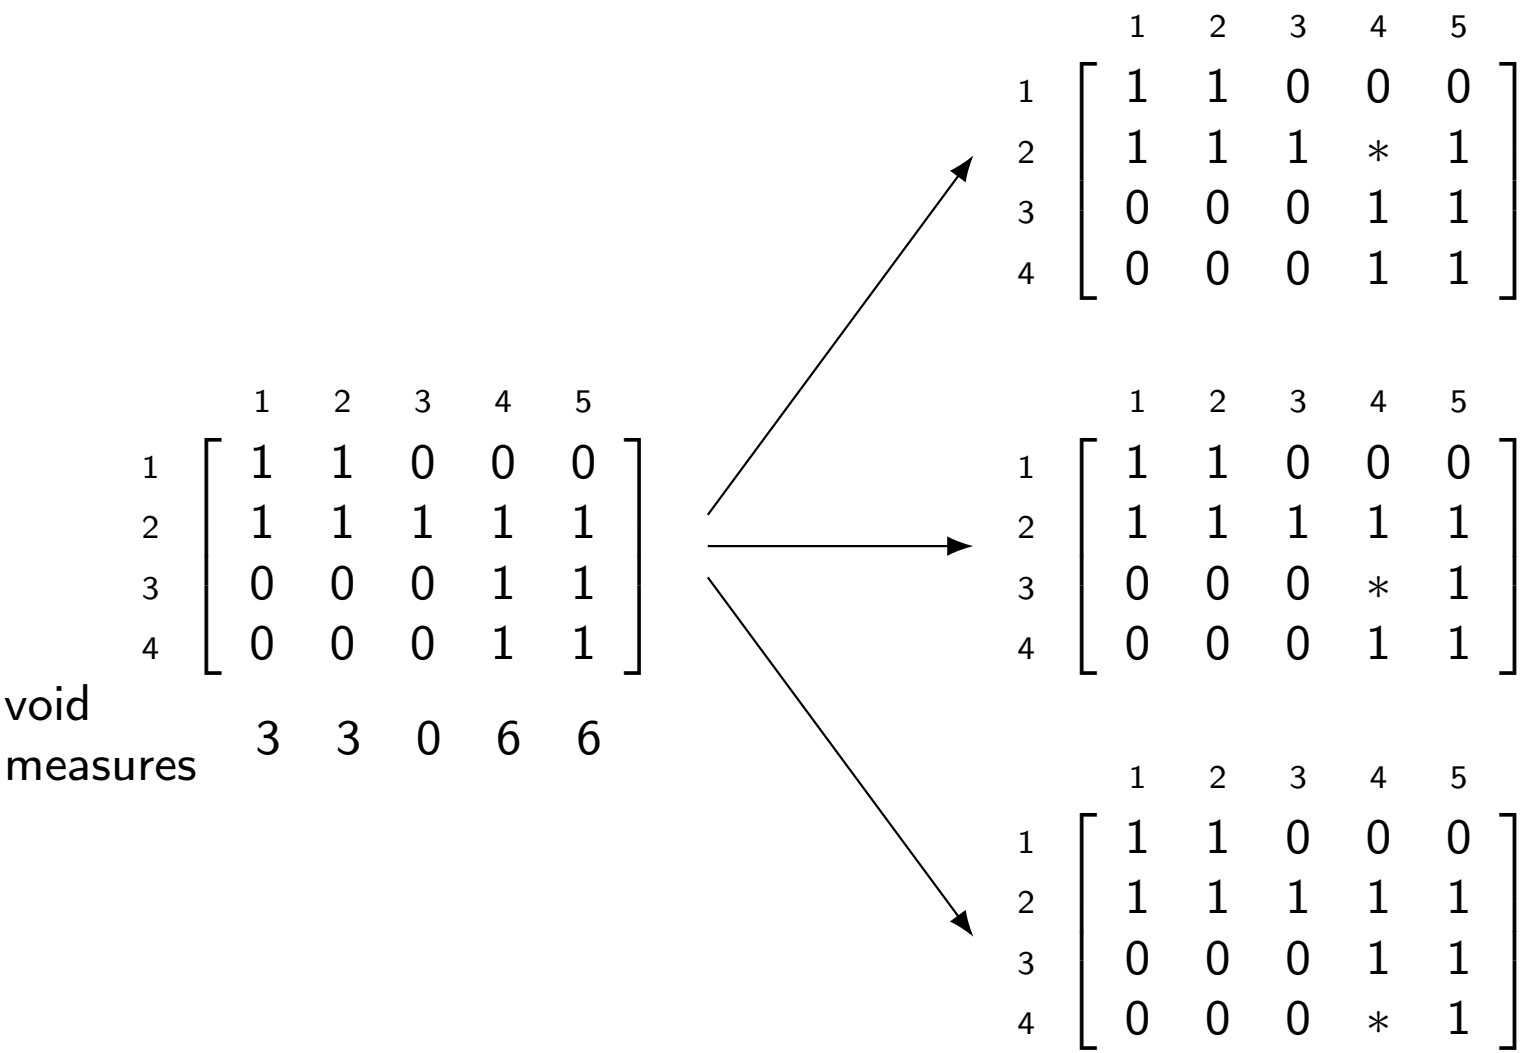

Метод ветвей и границ 2009 – 2

Распределение межкластерных элементов по матрицам в решении:

- (separate) составить отдельный фрагмент из межкластерных эелементов
- (nearest) добавить межкластерный столбец в тот фрагмент, где есть какая-то его часть
- (replicate) добавить в каждый фрагмент все необходимые межкластерные столбцы

Метод ветвей и границ 2011 – 1

нижняя граница: Z_L – глубина узла в дереве

верхняя граница: Z_U – минимальный Z_L среди найденных решений

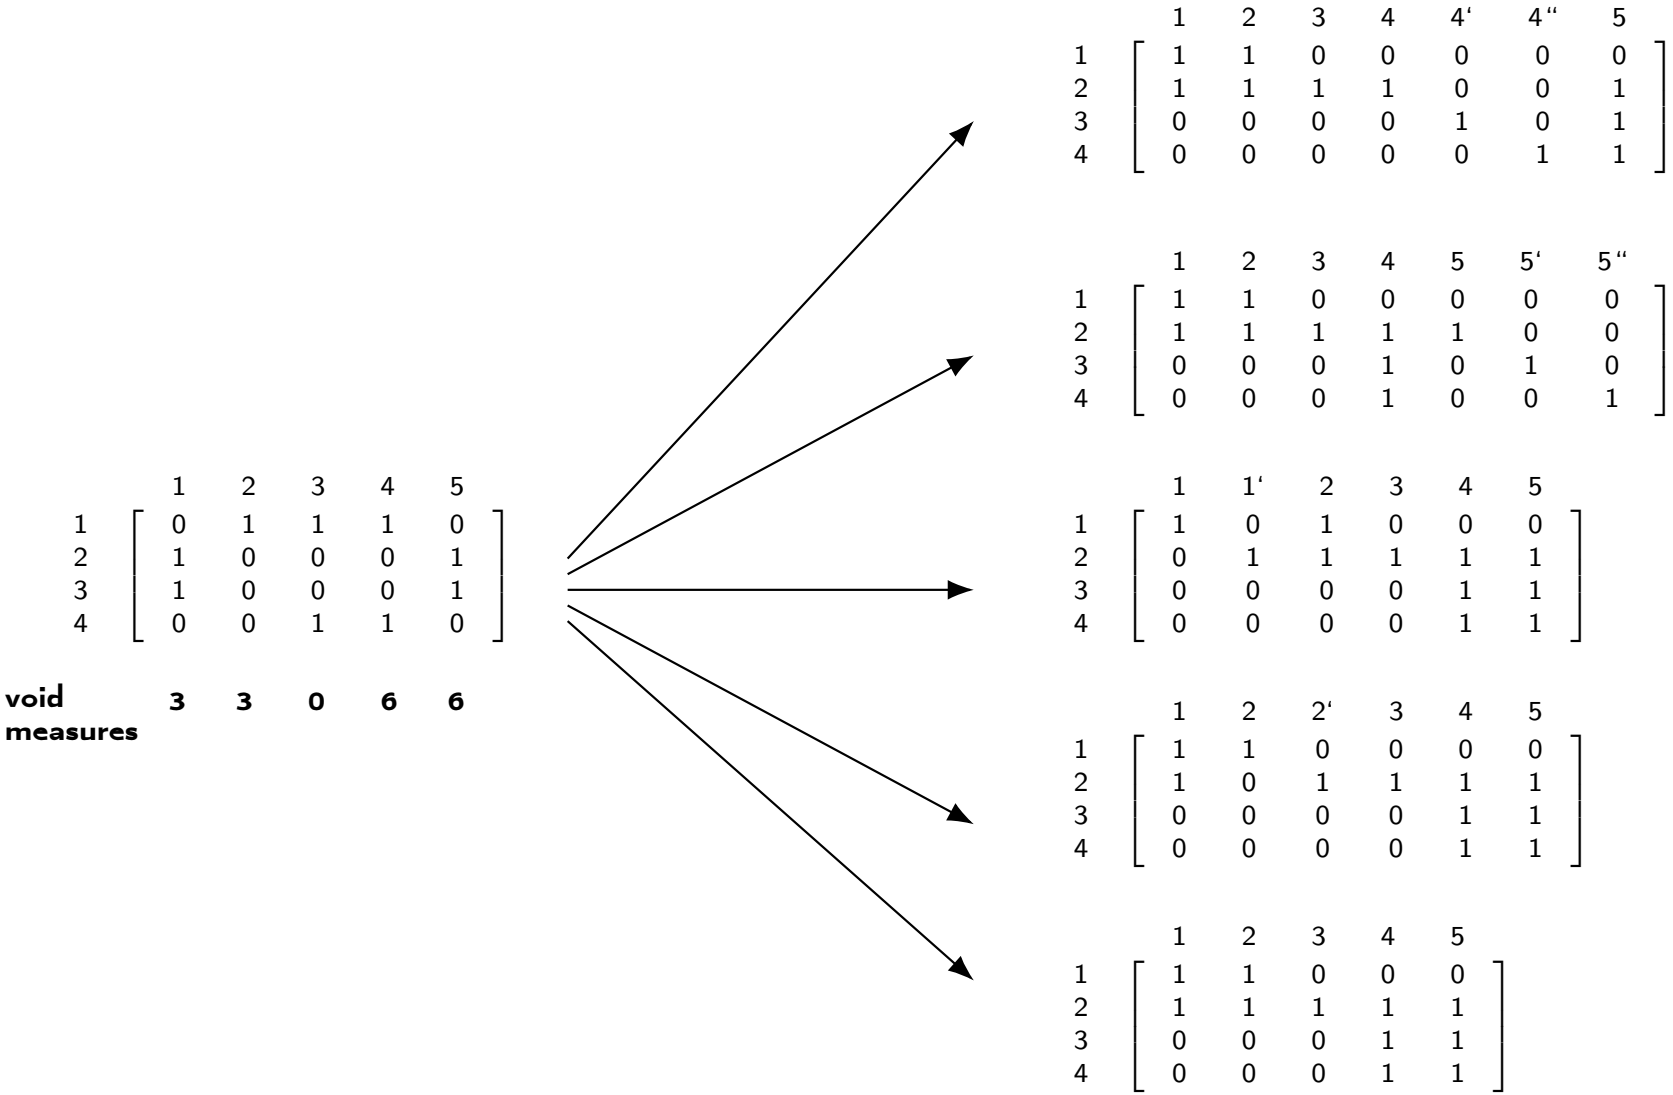

Метод ветвей и границ 2011 – 2

Постобработка решения

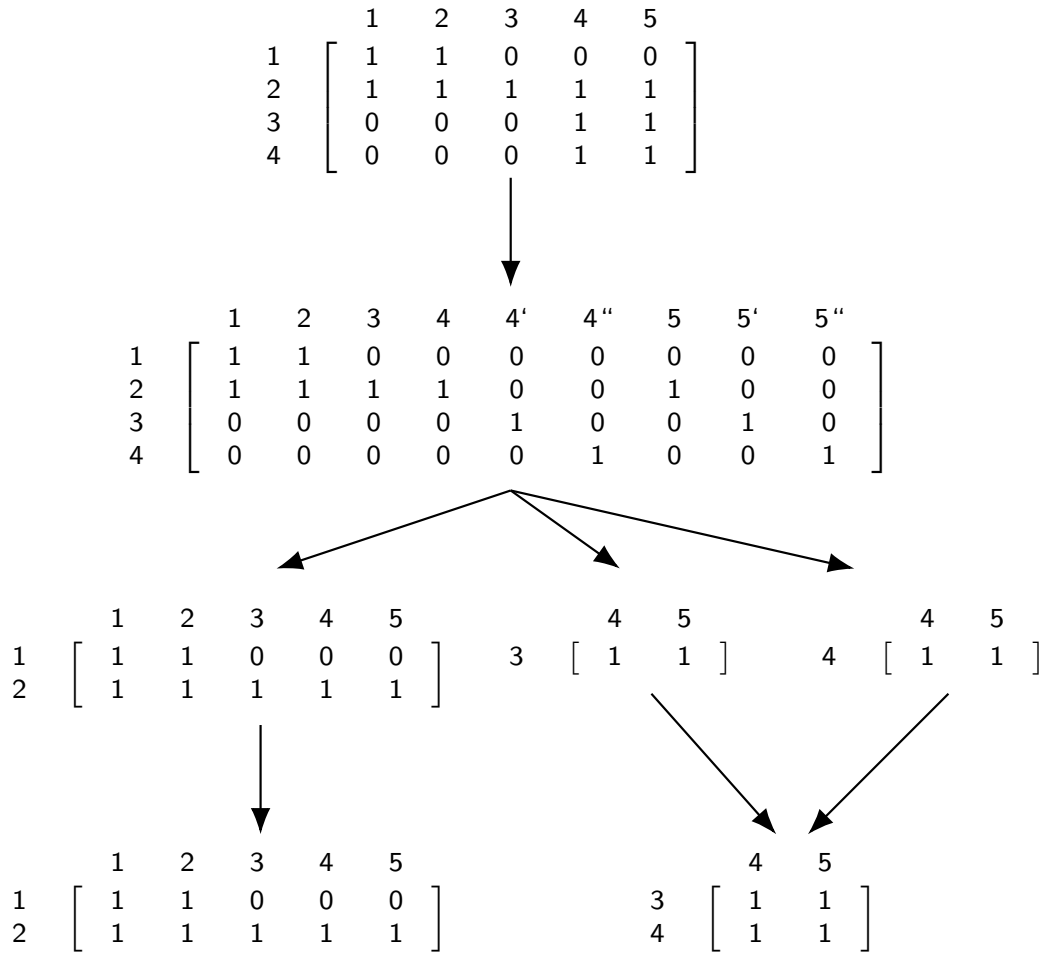

Тестовый стенд

Структура программы

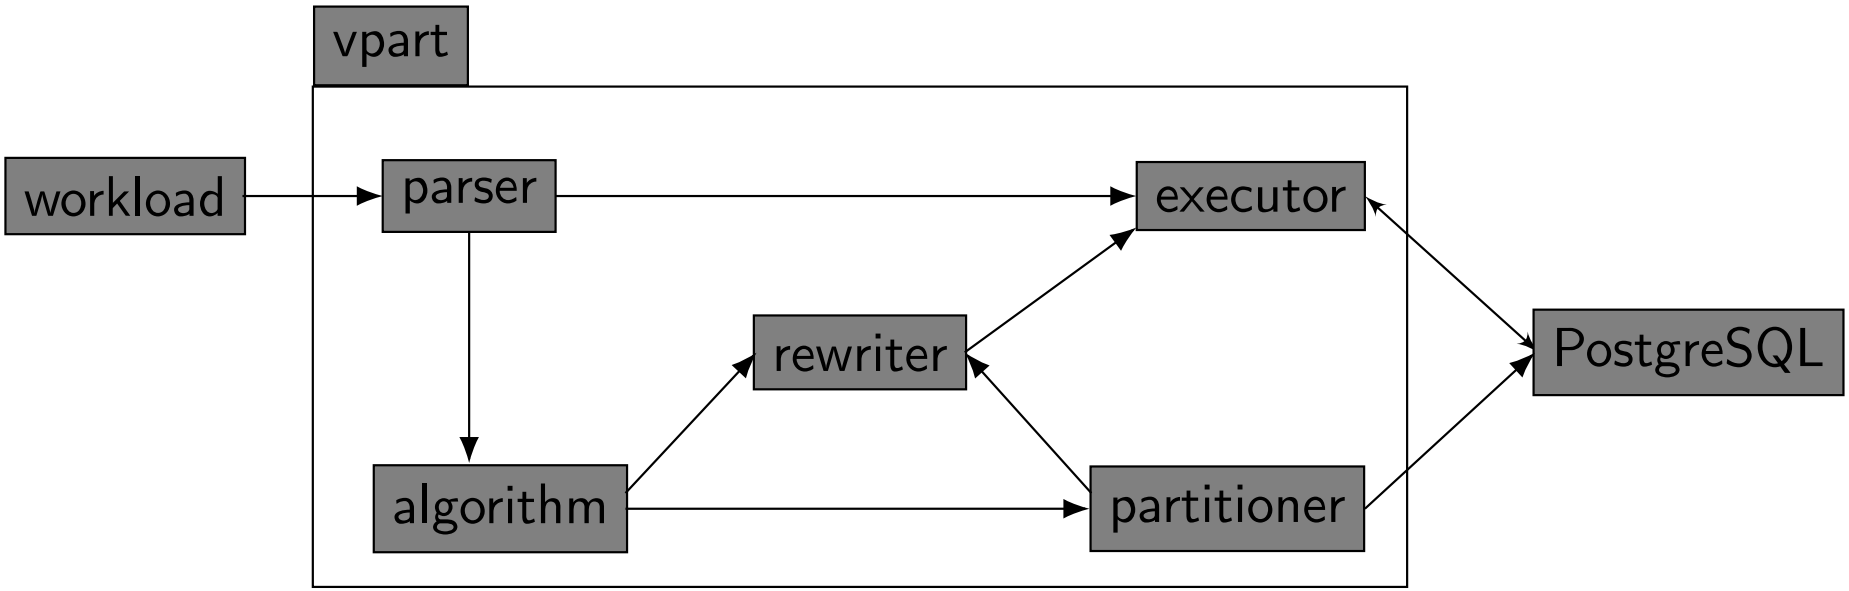

Критерии оценки алгоритмов:

- скорость кластеризации
- скорость выполнения запросов после применения алгоритма
- затраты памяти на хранение кластеров

Реализация

Аппаратные средства :

- Inspiron 15 7000 Gaming (0798)
- 8GiB RAM
- Intel(R) Core(TM) i5-7300HQ CPU @ 2.50GHz
- TOSHIBA 1TB MQ02ABD1

Программное обеспечение :

- Ubuntu 18.10
- PostgreSQL 11.1
- gcc 8.2.0

Датасет :

- SDSS Star table

Обеспечение чистоты экспериментов

$$\sum_{q_i \in Queries} \frac{size(T)}{time(q_i, T)} = \sum_{q_i \in Queries} \frac{size(table(q_i))}{time(q_i, table(qi))}$$

$size(T)$ – размер исходной таблицы в байтах
$size(table(q_i))$ – размер фрагмента, соответствующего запросу
$time(q_i, table)$ – время выполнения запроса к соответствующей таблице

- сбросить системный кеш : установить флаг 3 в `/proc/sys/vm/drop_caches`
- запретить параллельное выполнение запросов : set max_parallel_workers_per_gather to 0 ;

Эксперимент 1 – затраты памяти на фрагменты

- база данных SDSS-IV Data Release 14, 2016
- 8 запросов
- таблица "Star"
- 509 атрибутов, 492515 записей
- каждое показание является средним значением из 10 итераций

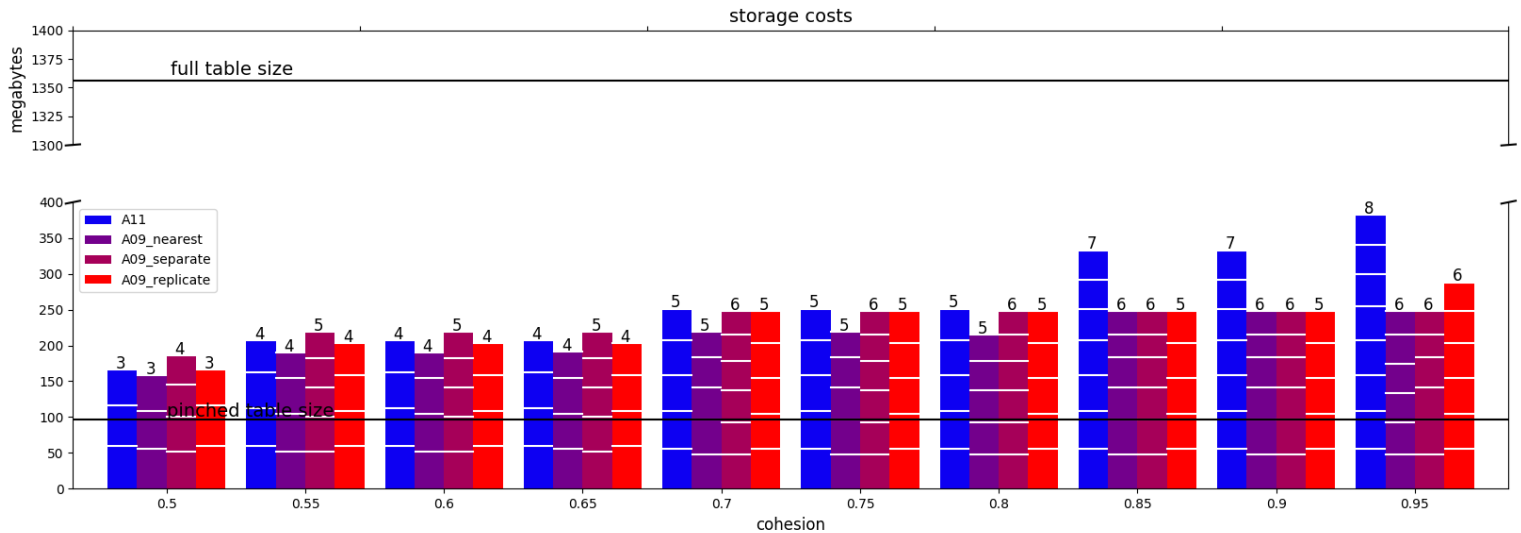

Эксперимент 1 – скорость выполнения запросов

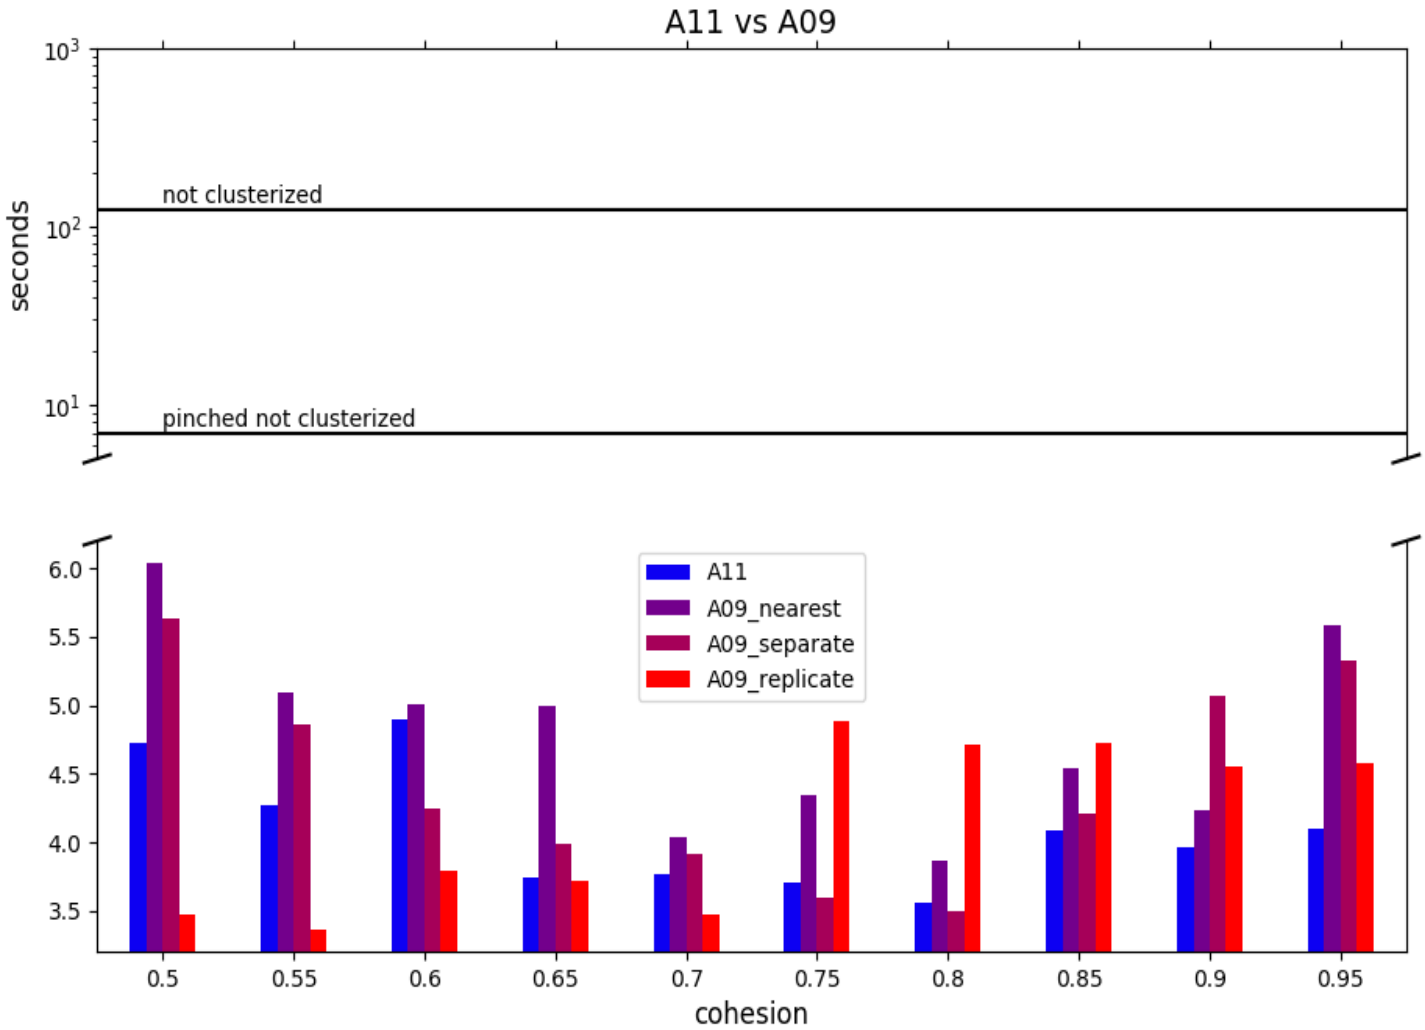

Эксперимент 1 – скорость получения фрагментов

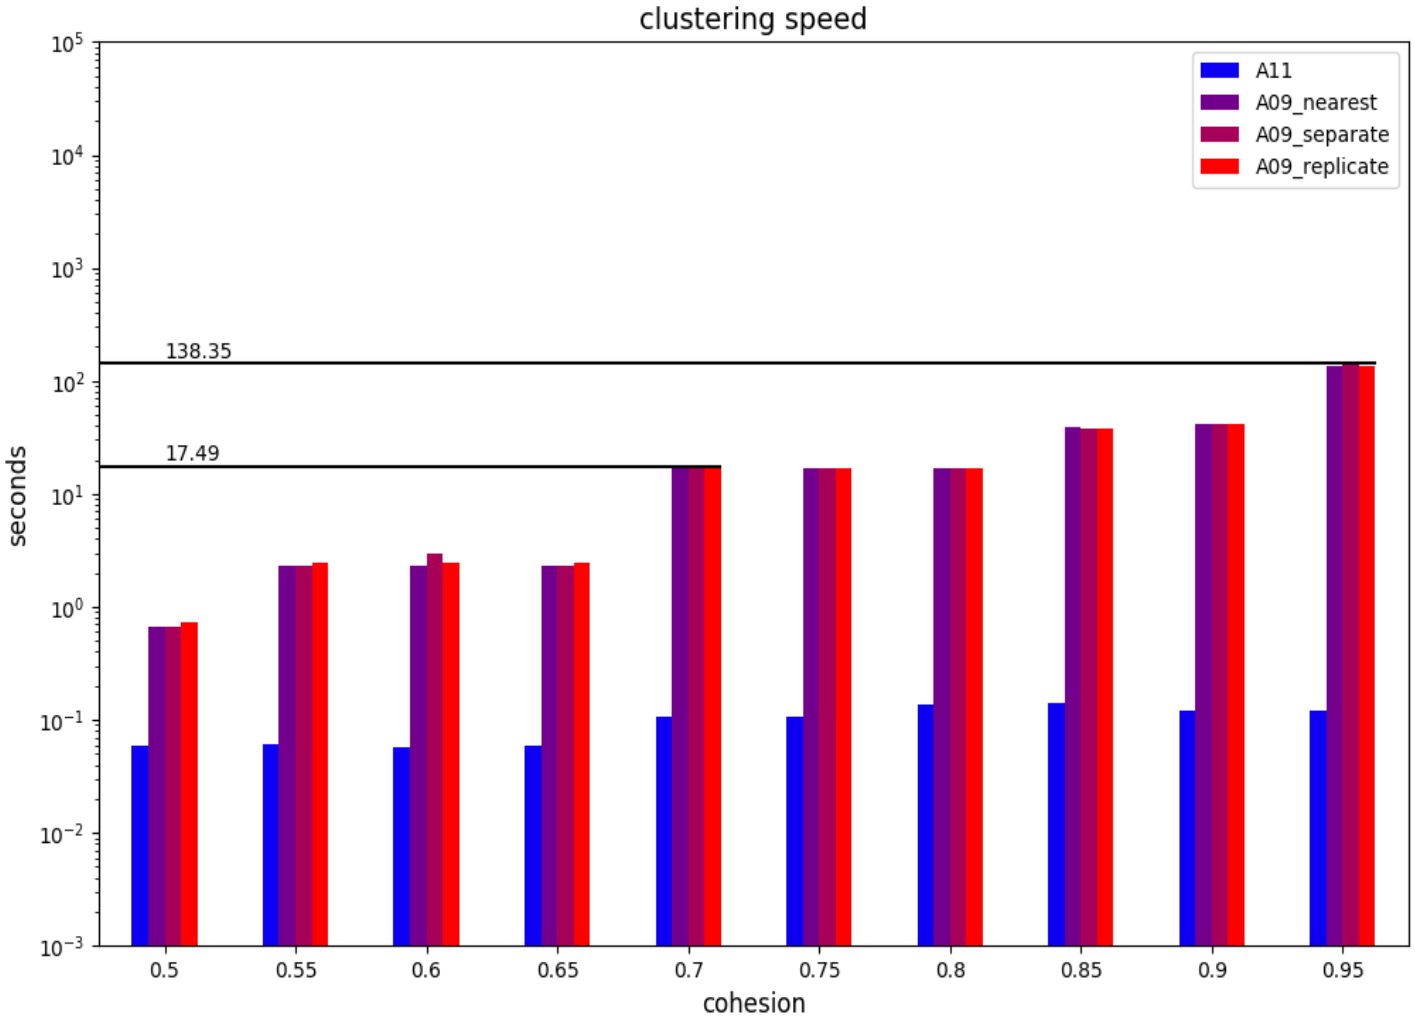

Эксперимент 2 – матрицы с фиксированным числом столбцов

- синтетические матрицы
- варьирование плотности и размера
- $threshold = 0.9$
- предел времени выполнения 2 часа

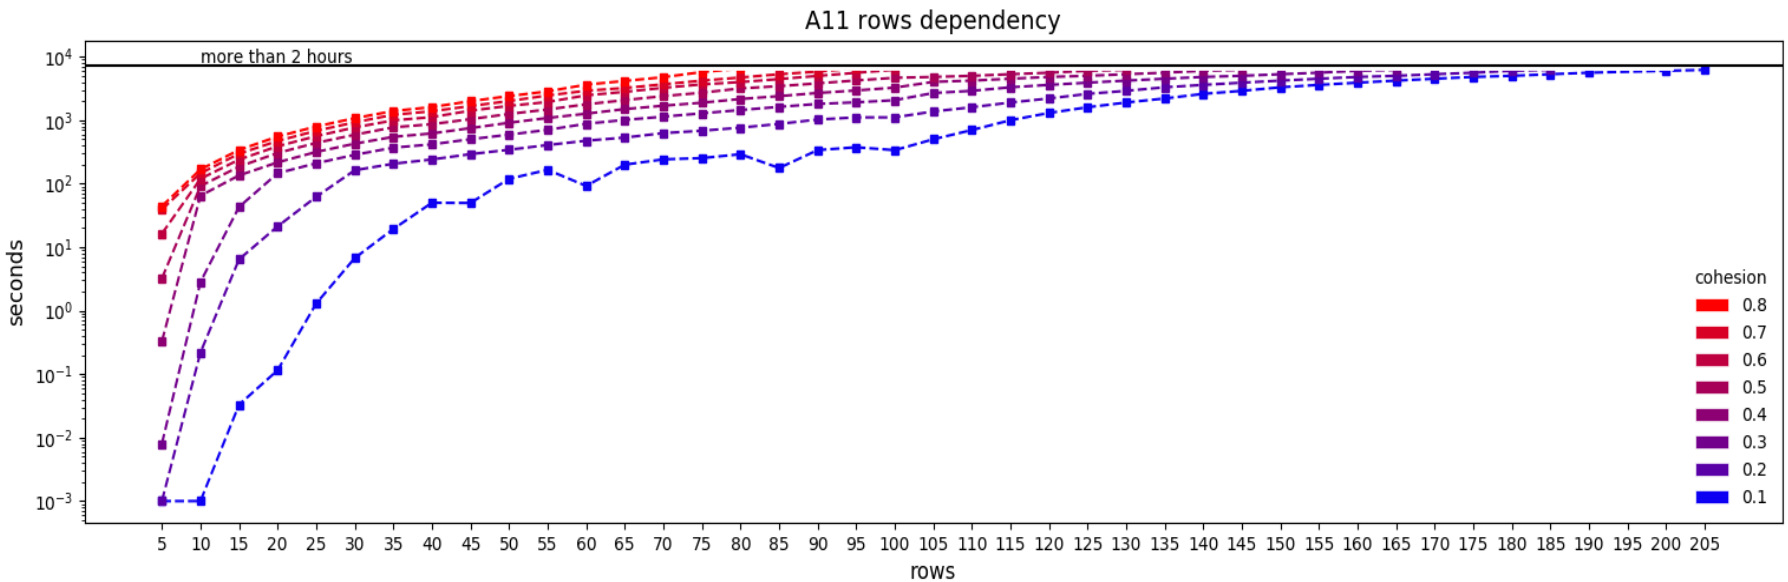

Эксперимент 2 – матрицы с фиксированным числом строк

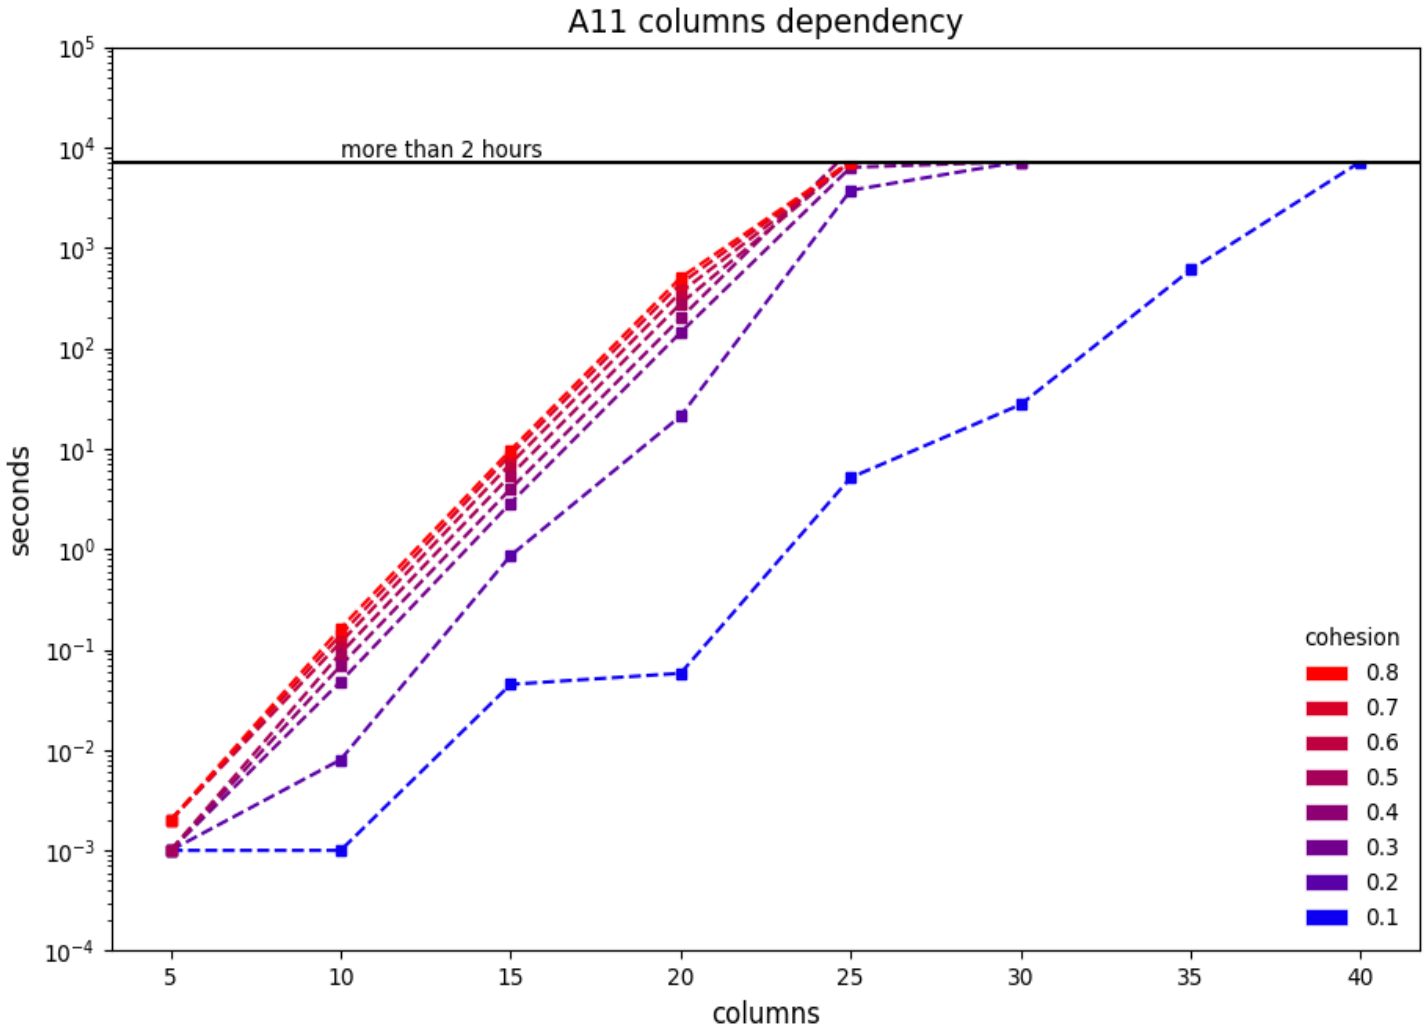

Эксперимент 2 – квадратные матрицы

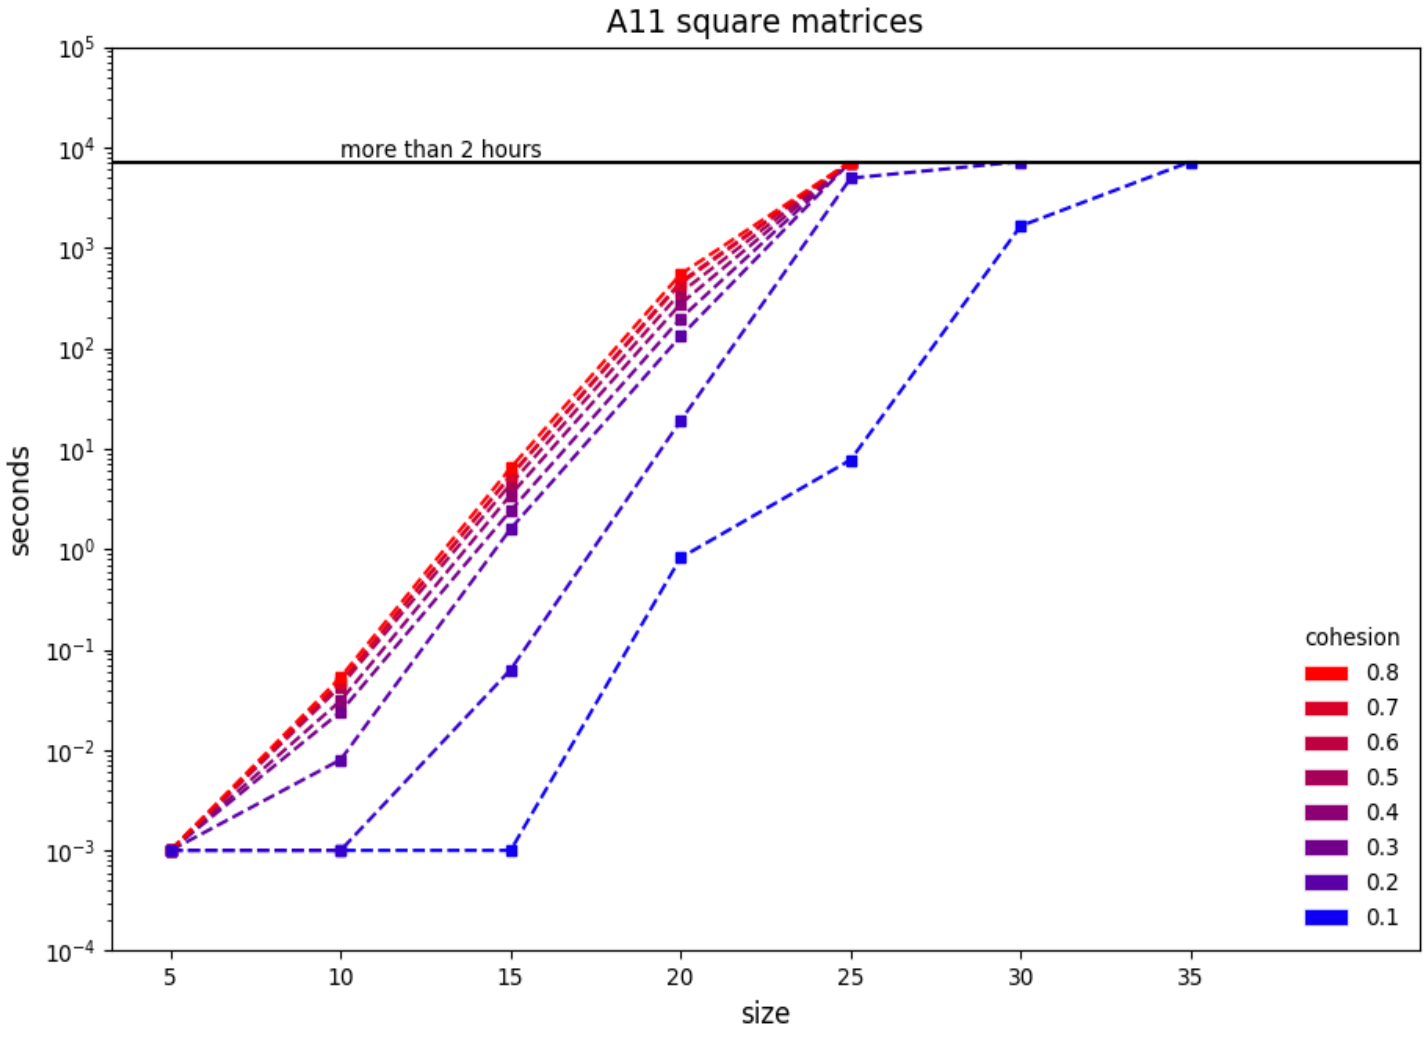

Выводы – 1

- Фрагментирование повышает производительность
- Качество фрагментов зависит от threshold. С этой точки зрения лучше всего работает A09 с replication.
- Топ-5 по скорости запросов к фрагментам:

время	алгоритм	стратегия	threshold
3.358	A09	replicate	0.55
3.472	A09	replicate	0.55
3.479	A09	replicate	0.70
3.500	A09	separate	0.80
3.553	A11		0.80

Выводы – 2

- При threshold $= 0.7$ суммарное время работы всех алгоритмов наименьшее.
- С данным датасетом A11 сработал почти в 10 раз быстрее, чем A09 вне зависимости от стратегии.
- Возрастание числа атрибутов замедляет работу алгоритмов быстрее, чем возрастание числа запросов.
- Наборы фрагментов, производимые алгоритмами, требуют в $1,5 - 2$ раза больше памяти, чем таблица, состоящая только из используемых атрибутов.